Korean MRC Question Answering

1조 김소연 김지수 안희진 정영빈

2021.11.16. 2nd MRC Project

Table of Contents

1. 프로젝트 개요

2. 프로젝트 팀 구성 및 역할

3. 프로젝트 진행 프로세스

4. 프로젝트 결과

5. 자체 평가 및 보완

목표/기대효과

한국어 지문을 보고 질문에 맞는 답을 생성하는 모델 설계

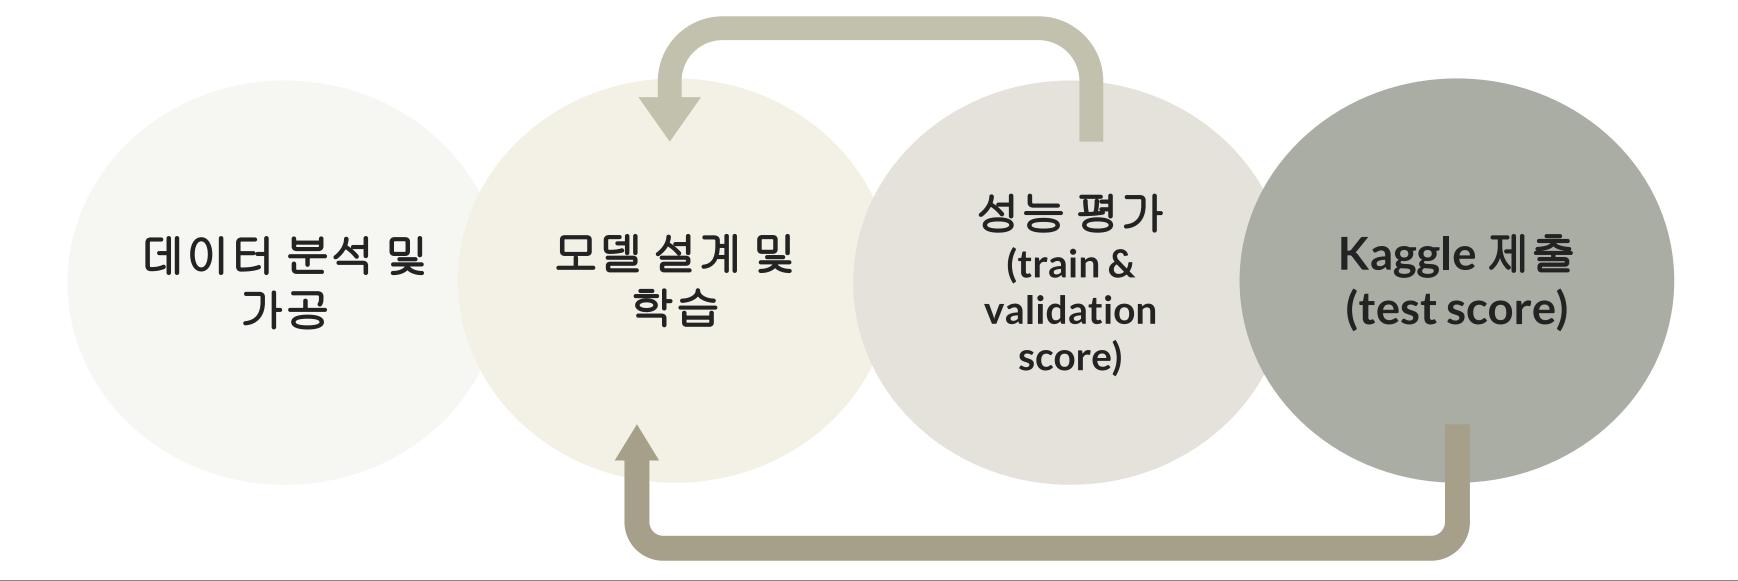
Frameworks & Libraries







진행프로세스



프로젝트 팀 구성 및 역할

훈련생	역할	담당 업무
김소연	팀장	 EDA 및 Pre-processing Data Augmentation Learning rate scheduler 추가 Post-processing 발표 자료 제작
김지수	팀원	 Metric(Levenstein, Exact match) 추가 Fine-tuning Evaluation, Prediction 코드 작성
안희진	팀원	 test labeling 및 Metric(Levenstein) 측정 코드작성 자료조사 및 Aihub 자료 제공 발표자료 제작
정영빈	팀원	 ● Baseline 리뷰 및 코드정리 ● Post-processing ● Ensemble

Start

Finish

	1주차					2주차				
	2일(화)	3일(수)	4일(목)	5일(금)	8일(월)	9일(화)	10일(수)	11일(목)	12일(금)	15일(월)
Baseline 분석 및 사전조사										
EDA 및 Pre-processing										
모델 선정 및 분석										
모델 평가 및 개선										

1. EDA 및 Preprocessing - 동일 Context, Question 에 대한 다른 Answers

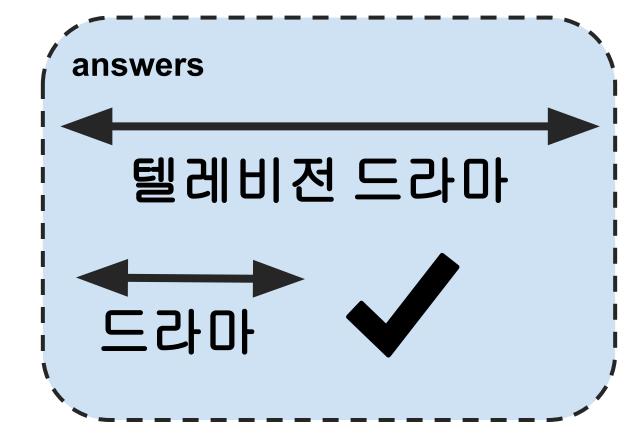
temp_train_df[temp_train_df.duplicated(["Question"], keep=False)].sort_value("contexts") > 10034rows

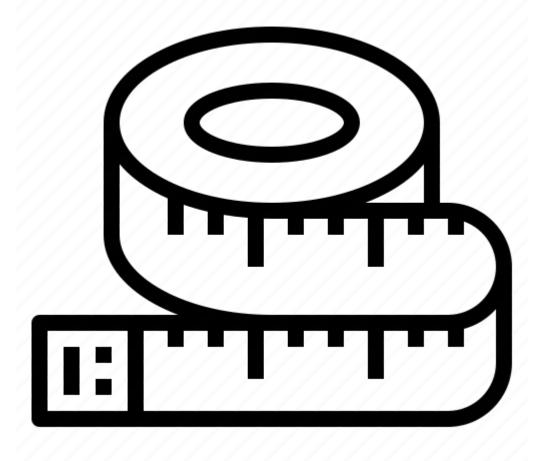
Contexts

"시간이동"은 미국의 방송사 ABC의 <u>텔레비전 드라마</u> 시리즈 로스트의 시즌 프리미어 에피소드 제목이다.

Questions

ABC에서 반영되는 '<u>시간이동</u>'의 장르는?

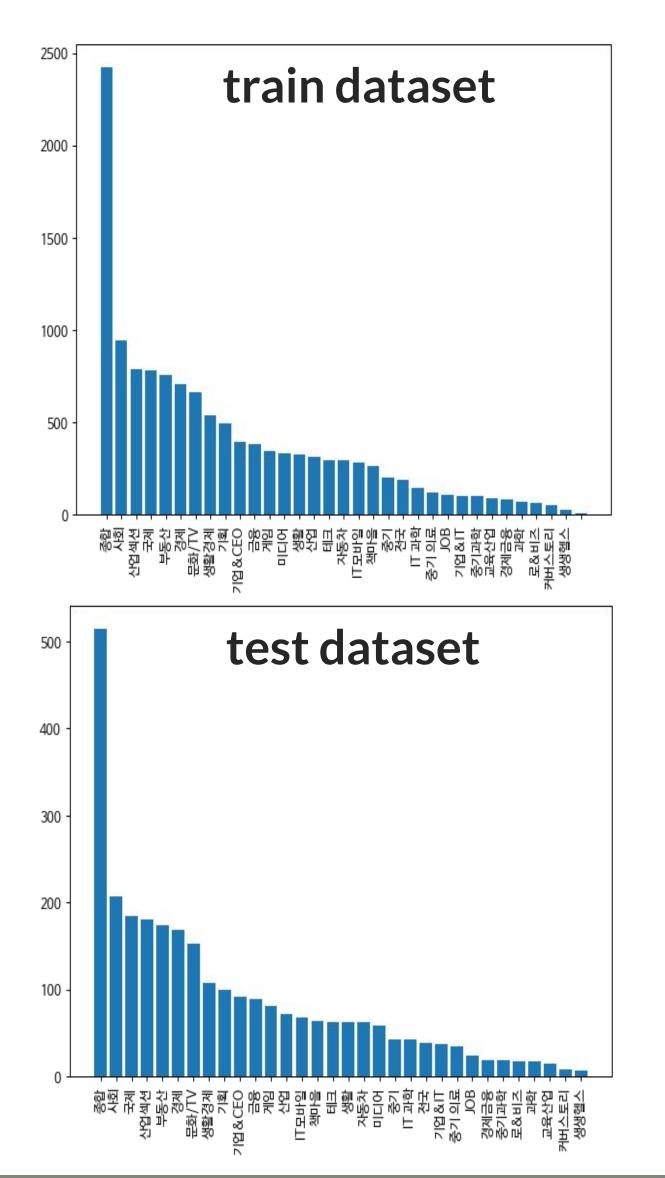




• edit distance

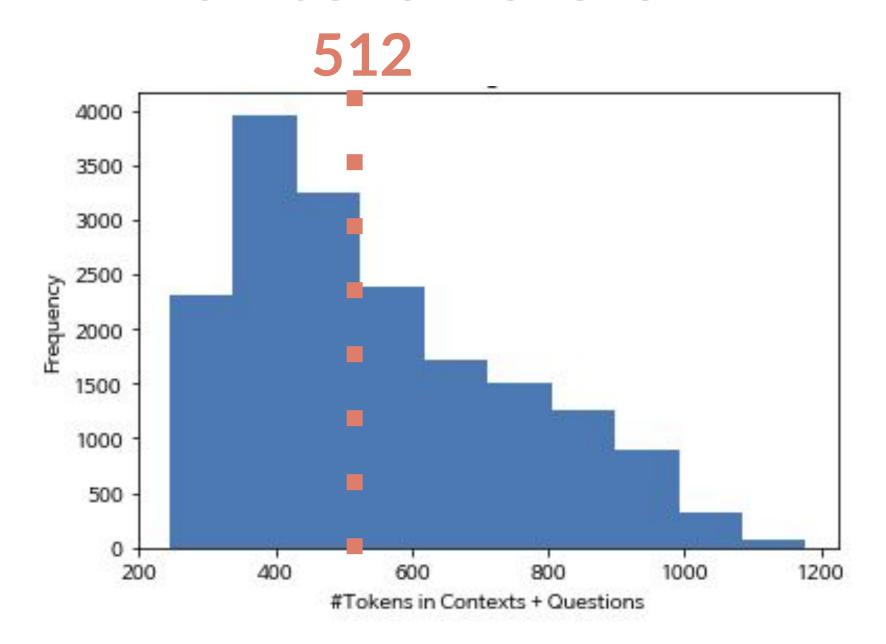
1. EDA 및 Preprocessing - Data Augmentation

Domain Distribution

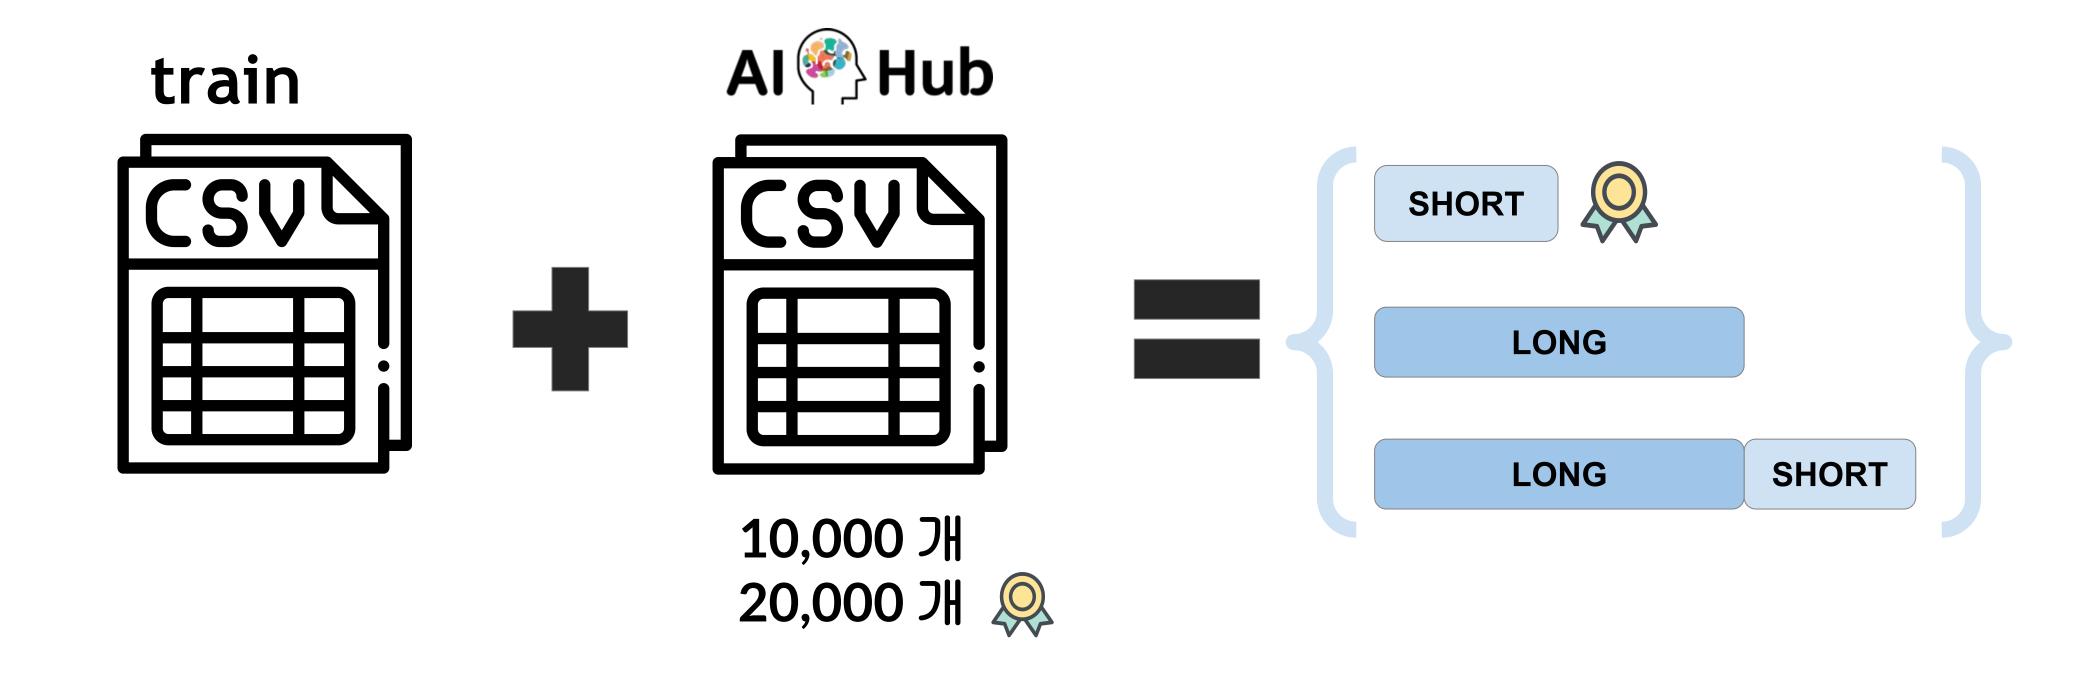




Number of Tokens





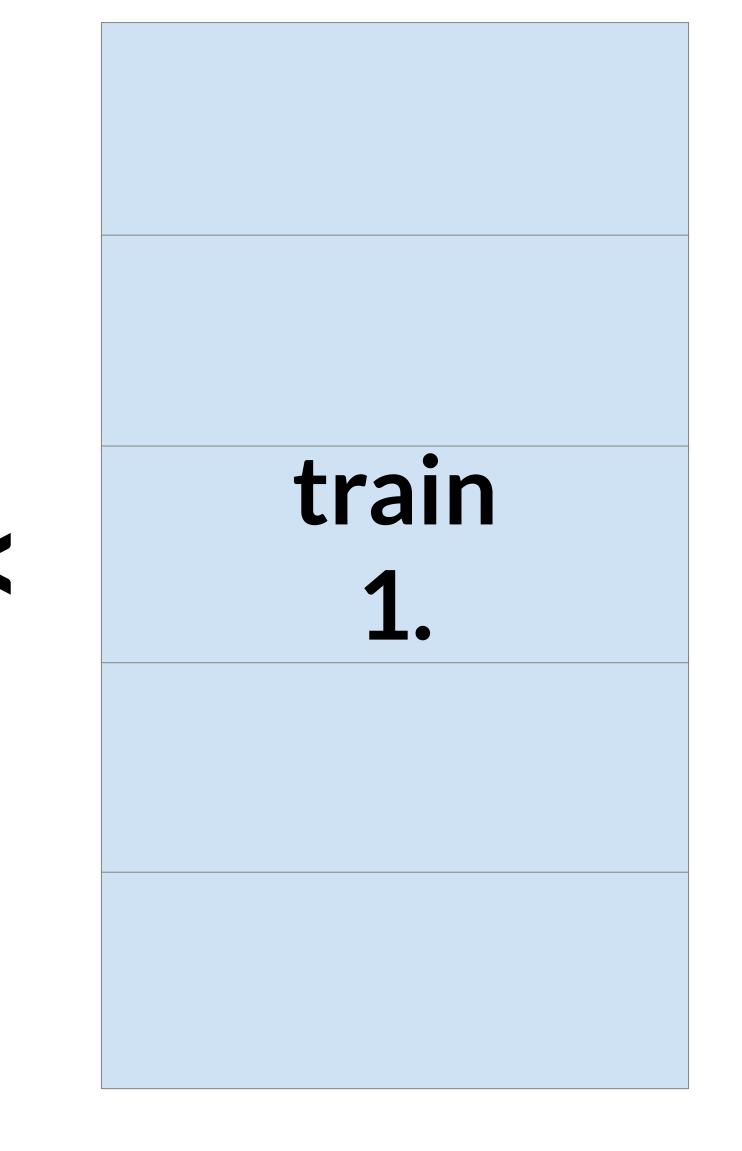




- (▼) ① Domain 불일치 ② Domain Distribution 변화

1. EDA 및 Preprocessing - Split Ratio





How to evaluate?



```
def edit_distance(data, test_data):
# csv파일 내 Nan값이 있으면 TypeError발생으로 인해 Nan값을 ''으로 채워준다.
data.fillna('', inplace=True)
test_data.fillna('', inplace=True)

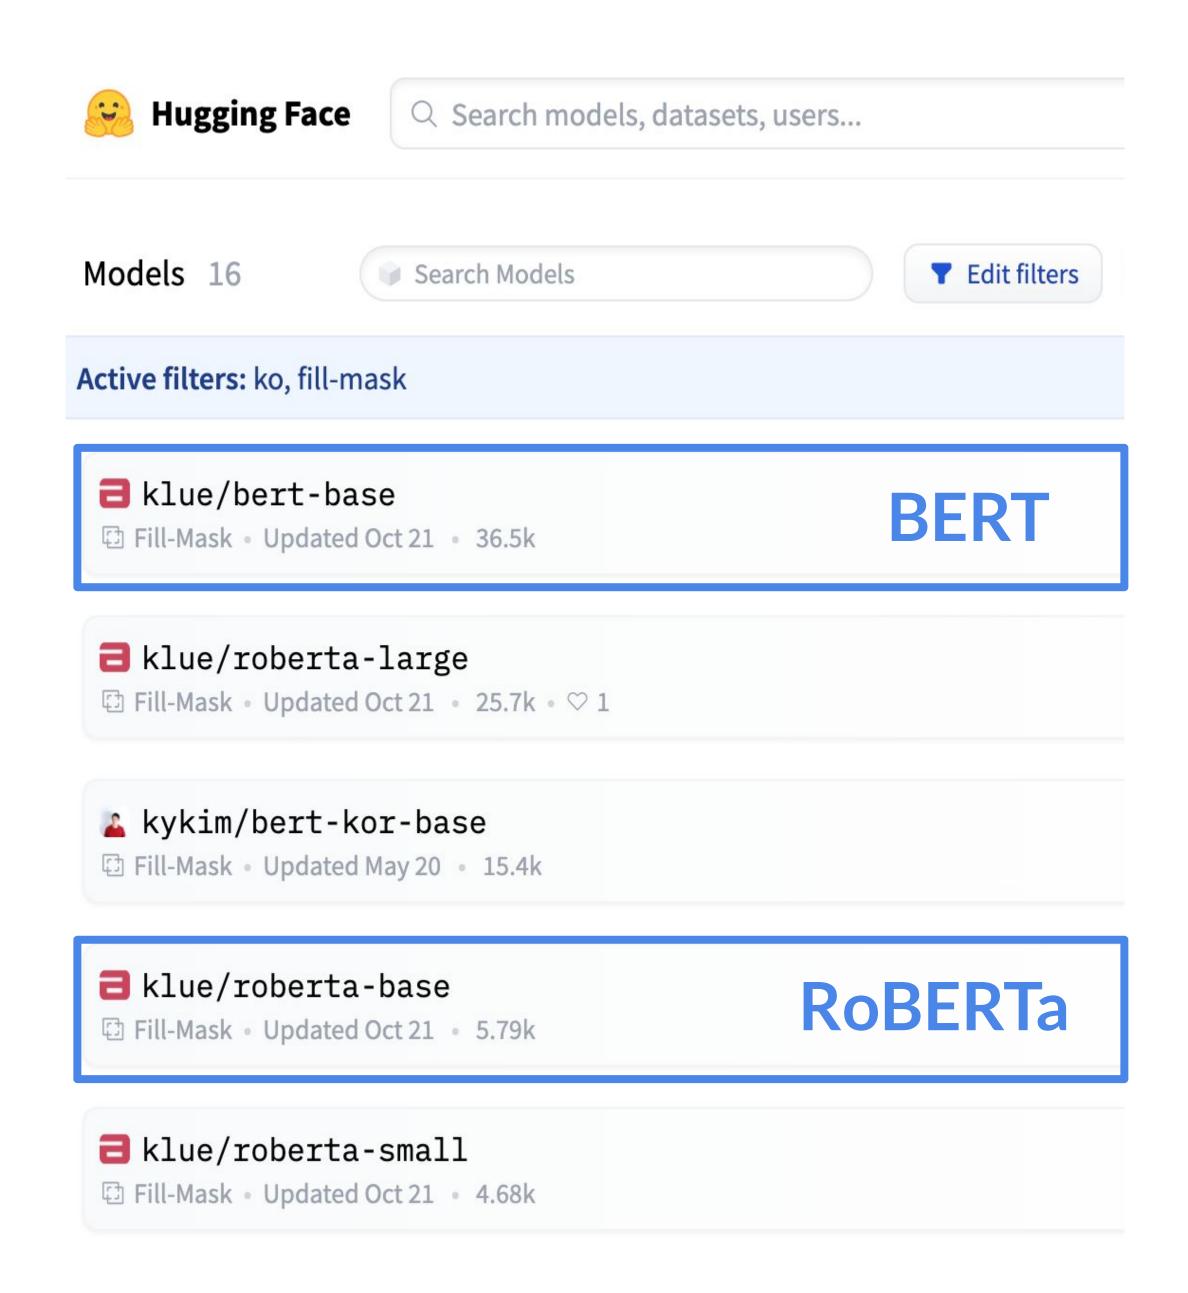
result = []

for i in range(len(data)):
    result.append(jamo_levenshtein(data['Predicted'][i], test_data['Predicted'][i]))

return np.mean(result) # 전체 평균으로 결과를 리턴한다.
```

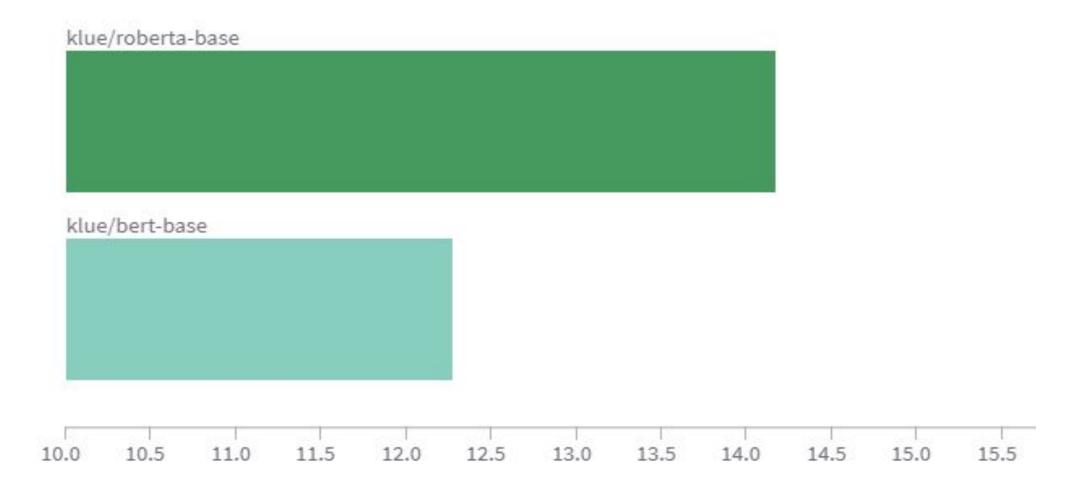
프로젝트결과

2. 모델 선정 및 분석



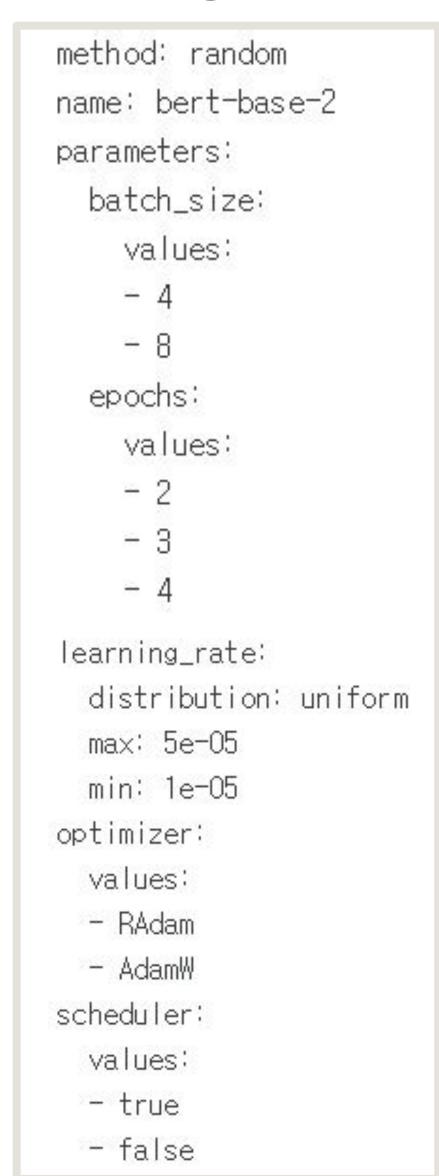
Metric (levenshtein)	KLUE/BERT-base	KLUE/RoBERTa-ba se
train.json	₽5.98 ∨	5 6.86
train.json +Aihub.json	14.80 V	s 11.22 &

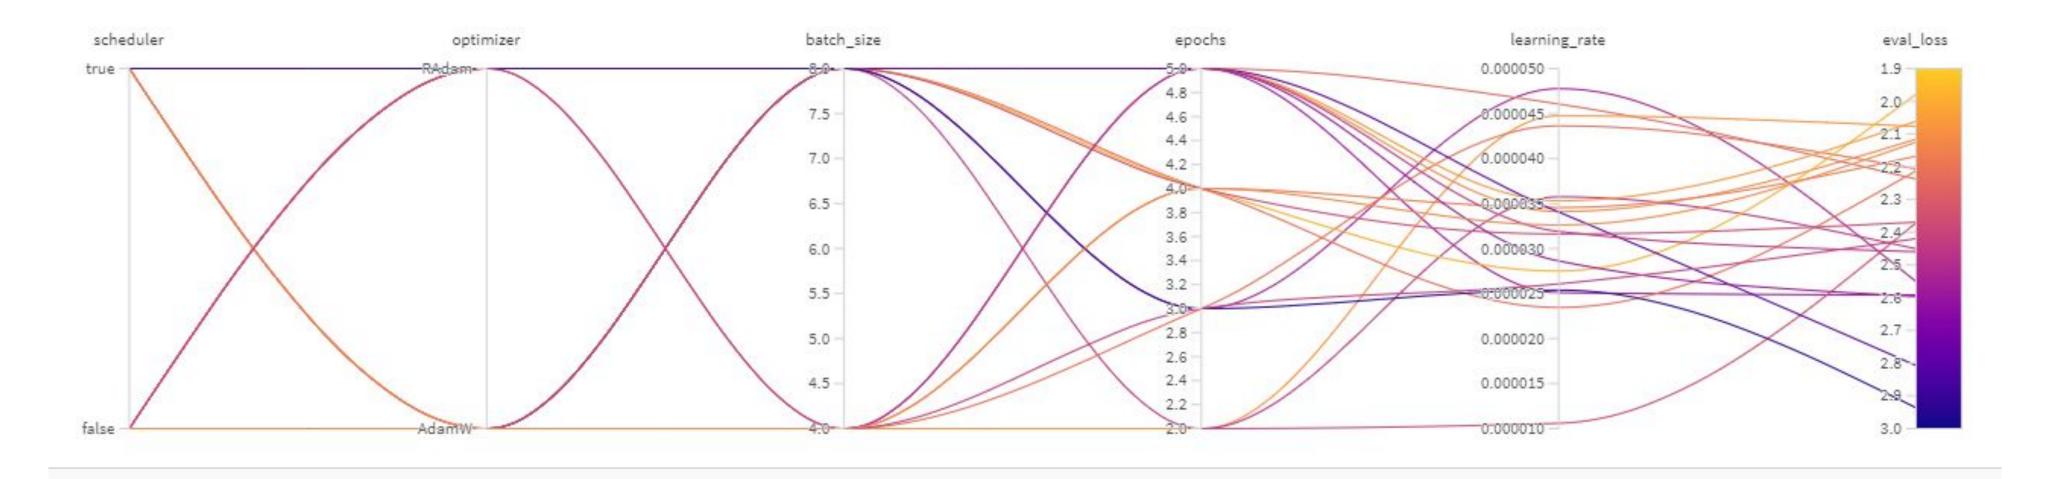
Levenshtein Distance (Lower is better)

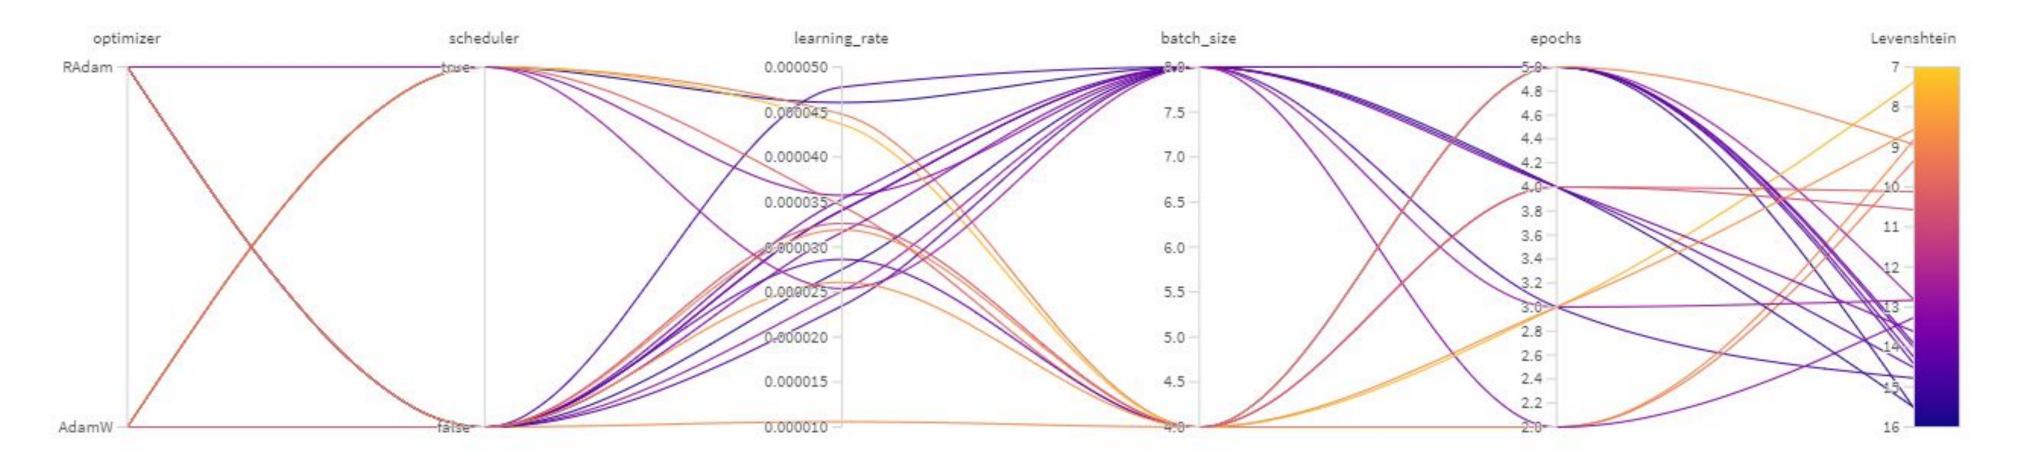


3. 모델 평가 및 개선 - Hyper-parameter Tuning

WandB Sweep Configuration

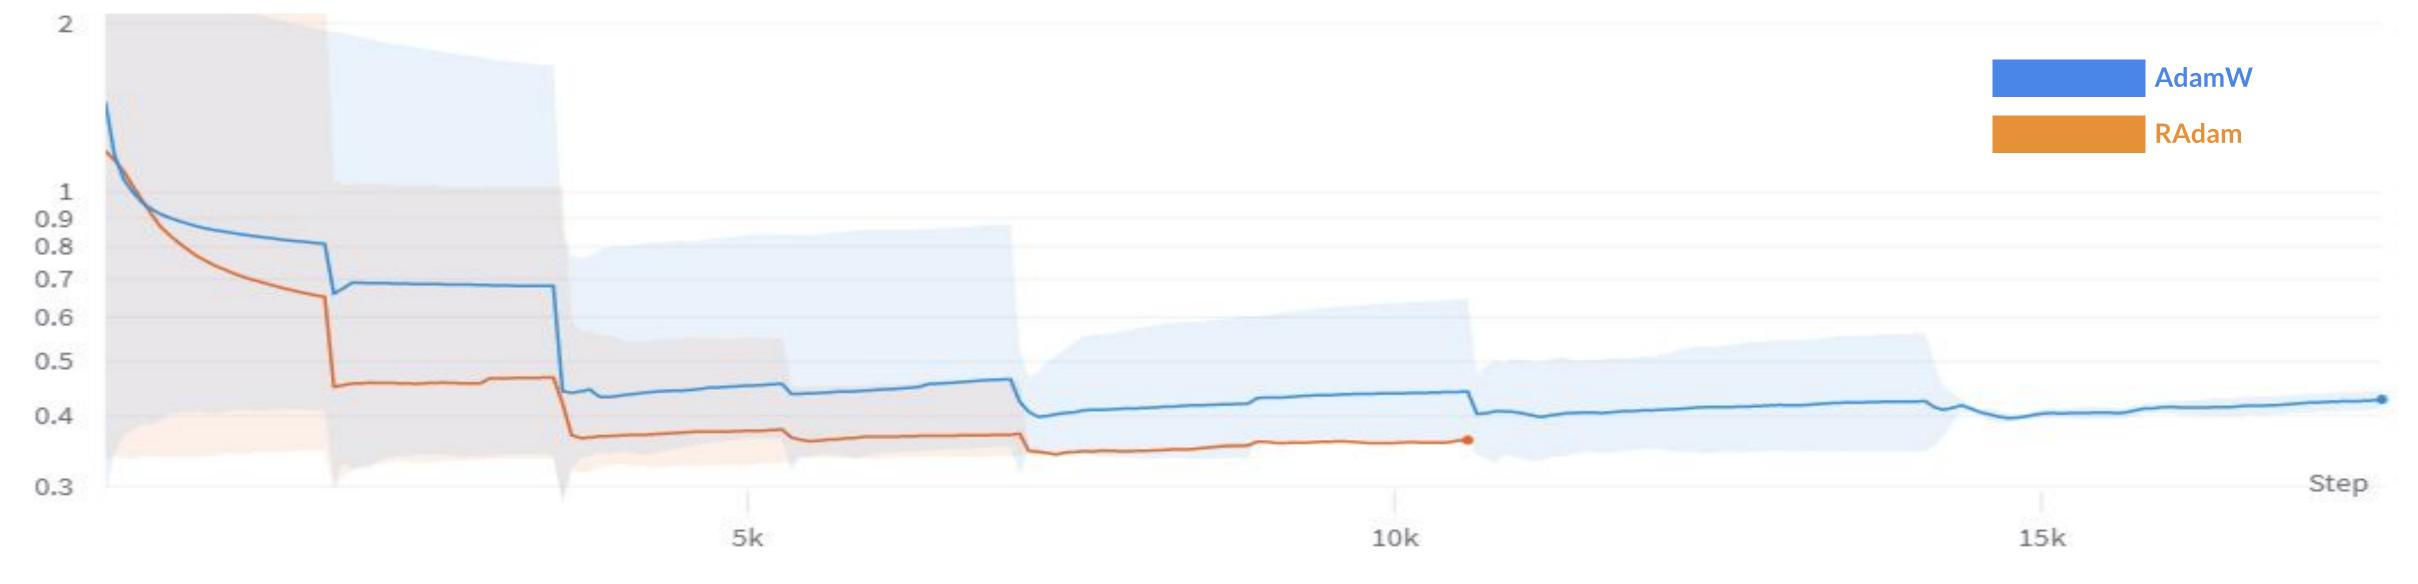






3. 모델 평가 및 개선 - Optimizer & Ir Scheduler

Optimizer에 따른 loss 평가

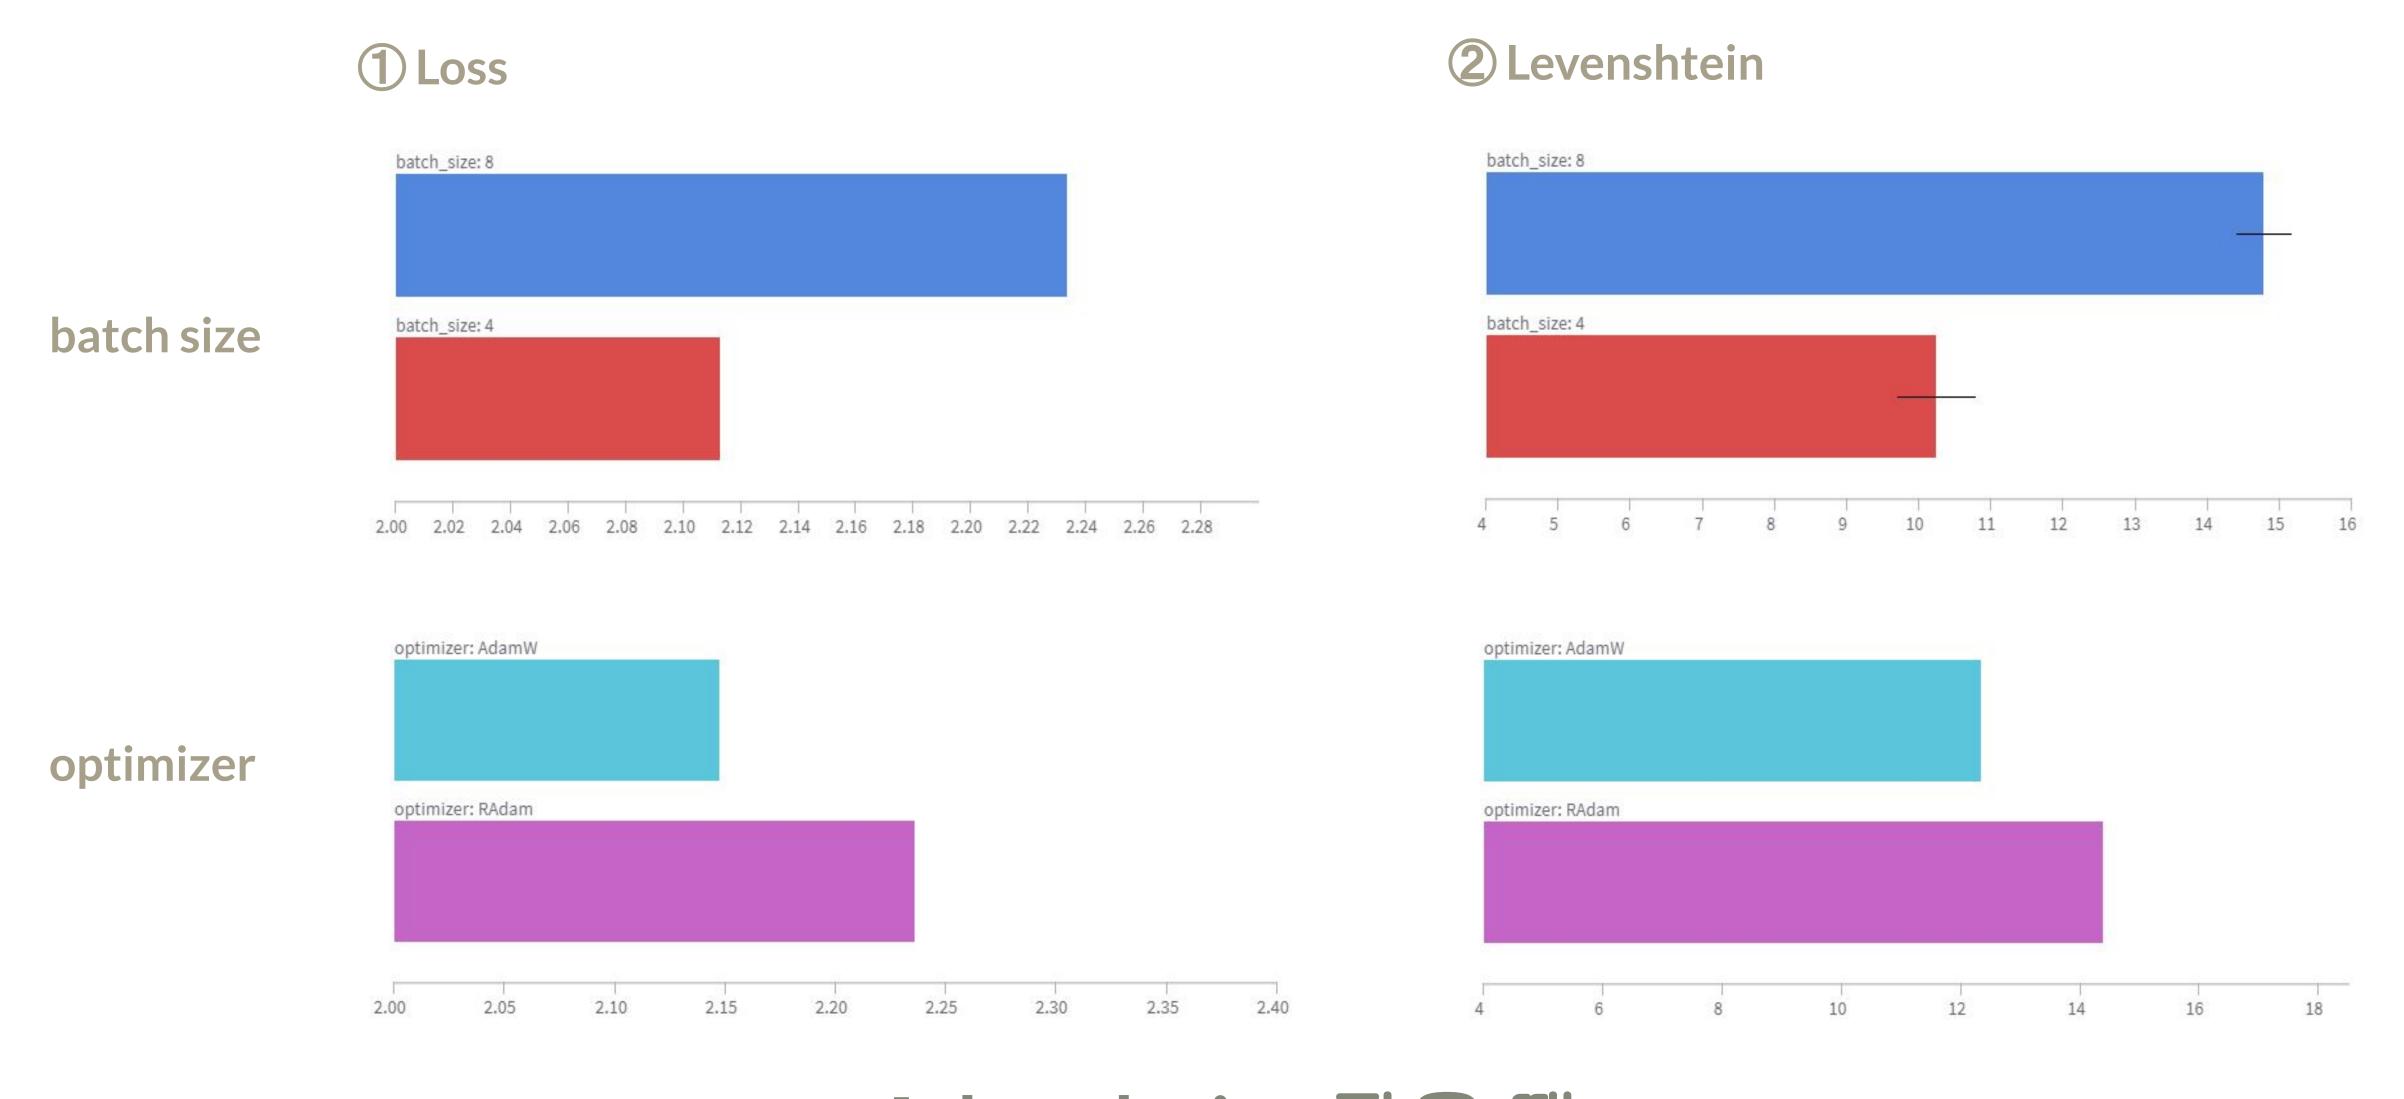


Ir Scheduler 유무에 따른 loss 평가



프로젝트결과

3. 모델 평가 및 개선 - Evaluation Metrics



... batch size 작을 때 AdamW 사용 했을 때

answers

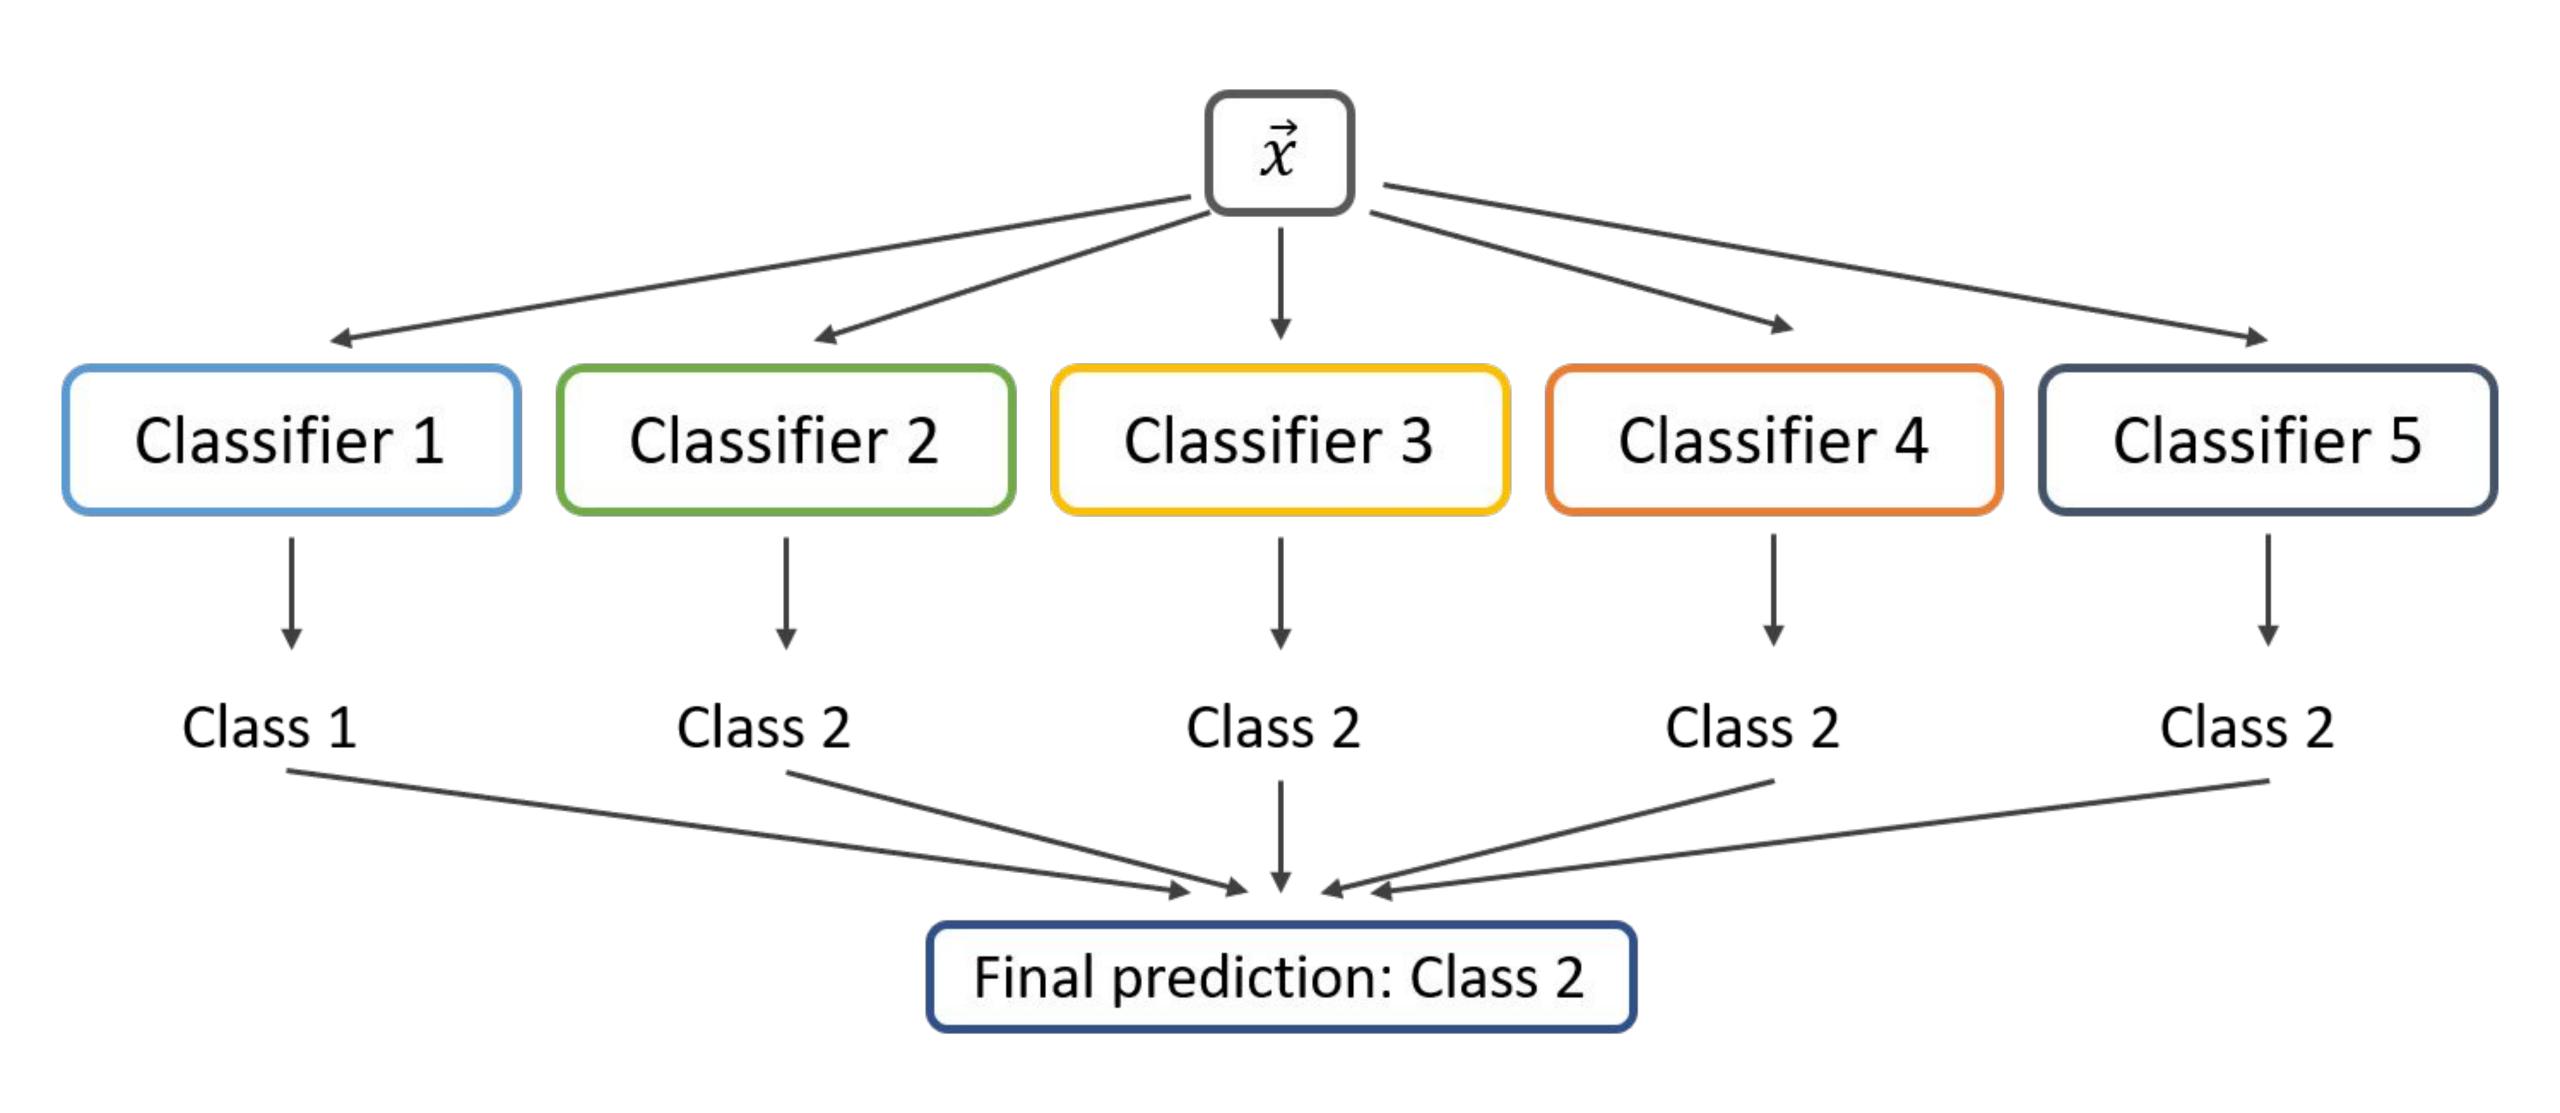
흙에서 영양물의 밸런스를 유지하기 위해

뒤에서부터 12글자 답변길이 자르기

answers

밸런스를 유지하기 위해

성능 향상 (▲) 6.7 → 2.9



최고 성능 달성! 2.68933

Team Name	Score		
1조	2.59334		



Pre-processing

Data Augmentation

Model

Others

한계

긴 문장들을 별도의 전처리 없이 사용

개선 방안

모델의 max_token_length 에 맞게 효과적인 input을 만들어주는 방법 고려

한계

문장의 길이만을 고려한 Random Sampling 방식

개선 방안

Domain Distribution을 고려한 data augmentation

한계

2가지의 extraction-based model 만을 이용

개선 방안

KoELECTRA 또는 T5 이용

한계

한 조합의 train/validation set 으로만 평가 -> 모든 train set 을 이용하지 못함

개선 방안

k-fold validation 이용

Reference

https://arxiv.org/pdf/1810.04805.pdf

https://huggingface.co/models?language=ko&sort=downloads&search=bert

https://huggingface.co/klue/bert-base

https://github.com/ainize-team/klue-mrc-workspace/blob/master/klue-bert-base-mrc.ipynb

https://towardsdatascience.com/question-answering-with-a-fine-tuned-bert-bc 4dafd45626

Thankyou

Contacts

mynameissoyeonkim@gmail.com

kuotientdev@gmail.com

annigin46@gmail.com

ybok2005@gmail.com

Github

https://github.com/SYKflyingintheSKY/Question-Answering